

Міністерство освіти і науки України
Національний технічний університет України «Київський політехнічний
інститут імені Ігоря Сікорського»
Факультет інформатики та обчислювальної техніки

Кафедра інформатики та програмної інженерії

Звіт

з лабораторної роботи № 1 з дисципліни
«Проектування алгоритмів»

„Проектування і аналіз алгоритмів зовнішнього сортування”

Виконав(ла)

ІІІ-35 Адаменко А. Б.
(шифр, прізвище, ім'я, по батькові)

Перевірив

Головченко М.М.
(прізвище, ім'я, по батькові)

Київ 2024

ЗМІСТ

1	МЕТА ЛАБОРАТОРНОЇ РОБОТИ.....	3
2	ЗАВДАННЯ.....	4
3	ВИКОНАННЯ.....	6
3.1	ПСЕВДОКОД АЛГОРИТМУ.....	6
3.2	ПРОГРАМНА РЕАЛІЗАЦІЯ АЛГОРИТМУ.....	6
3.2.1	<i>Вихідний код.....</i>	<i>6</i>
	ВИСНОВОК.....	7
	КРИТЕРІЇ ОЦІНЮВАННЯ.....	8

1 МЕТА ЛАБОРАТОРНОЇ РОБОТИ

Мета роботи – вивчити основні алгоритми зовнішнього сортування та способи їх модифікації, оцінити поріг їх ефективності.

2 ЗАВДАННЯ

Згідно варіанту (таблиця 2.1), розробити та записати алгоритм зовнішнього сортування за допомогою псевдокоду (чи іншого способу за вибором).

Виконати програмну реалізацію алгоритму на будь-якій мові програмування та відсортувати випадковим чином згенерований масив цілих чисел, що зберігається у файлі (розмір файлу має бути не менше 10 Мб, можна значно більше).

Здійснити модифікацію програми і відсортувати випадковим чином згенерований масив цілих чисел, що зберігається у файлі розміром не менше ніж двократний обсяг ОП вашого ПК. Досягти швидкості сортування з розрахунку 1Гб на 3хв. або менше. Достатньо штучно обмежити доступну ОП, для уникнення багатогодинних сортувань (наприклад використовуючи віртуальну машину).

Рекомендується попередньо впорядкувати серії елементів довжиною, що займає не менше 100Мб або використати інші підходи для пришвидшення процесу сортування.

Зробити узагальнений висновок з лабораторної роботи, у якому порівняти базову та модифіковану програми. У висновку деталізувати, які саме модифікації було виконано і який ефект вони дали.

Таблиця 2.1 – Варіанти алгоритмів

№	Алгоритм сортування
1	Пряме злиття
2	Природне (адаптивне) злиття
3	Збалансоване багатошляхове злиття
4	Багатофазне сортування
5	Пряме злиття
6	Природне (адаптивне) злиття
7	Збалансоване багатошляхове злиття

8	Багатофазне сортування
9	Пряме злиття
10	Природне (адаптивне) злиття
11	Збалансоване багатошляхове злиття
12	Багатофазне сортування
13	Пряме злиття
14	Природне (адаптивне) злиття
15	Збалансоване багатошляхове злиття
16	Багатофазне сортування
17	Пряме злиття
18	Природне (адаптивне) злиття
19	Збалансоване багатошляхове злиття
20	Багатофазне сортування
21	Пряме злиття
22	Природне (адаптивне) злиття
23	Збалансоване багатошляхове злиття
24	Багатофазне сортування
25	Пряме злиття
26	Природне (адаптивне) злиття
27	Збалансоване багатошляхове злиття
28	Багатофазне сортування
29	Пряме злиття
30	Природне (адаптивне) злиття
31	Збалансоване багатошляхове злиття
32	Багатофазне сортування
33	Пряме злиття
34	Природне (адаптивне) злиття
35	Збалансоване багатошляхове злиття

3 ВИКОНАННЯ

3.1 Псевдокод алгоритму

```
Function MergeAt(m, l, r, chk, m_idx, l_beg, l_sz, r_beg, r_sz)
    l_idx = l_beg
    r_idx = r_beg

    While (l_idx < l_sz AND l_idx - l_beg < chk) AND (r_idx < r_sz AND
r_idx - r_beg < chk)
        l_val = l.GetInt(l_idx)
        r_val = r.GetInt(r_idx)

        If l_val <= r_val
            m.SetInt(m_idx, l_val)
            l_idx = l_idx + 1
        Else
            m.SetInt(m_idx, r_val)
            r_idx = r_idx + 1

        m_idx = m_idx + 1

    While l_idx < l_sz AND l_idx - l_beg < chk
        m.SetInt(m_idx, l.GetInt(l_idx))
        l_idx = l_idx + 1
        m_idx = m_idx + 1

    While r_idx < r_sz AND r_idx - r_beg < chk
        m.SetInt(m_idx, r.GetInt(r_idx))
        r_idx = r_idx + 1
        m_idx = m_idx + 1

Function SortAtScale(m, l, r, c)
    s = m.Length()

    ls = 0
    rs = 0

    For i from 0 to s - 1
        lrChoice = (i // c) AND 1

        blockOffset = (i // (2 * c)) * c
        index = i % c

        [l, r][lrChoice].SetInt(
            blockOffset + index
            , m.GetInt(i)
        )

        If lrChoice == 0
            ls = ls + 1
        Else
            rs = rs + 1

    m_idx = 0
    lr_idx = 0

    While m_idx < s
        MergeAt(
            m, l, r,
            c,
            m_idx,
```

```

        lr_idx, ls,
        lr_idx, rs
    )

    m_idx = m_idx + 2 * c
    lr_idx = lr_idx + c

Function DirectMergeSort(m, l, r)
    s = m.Length()

    c = 1
    While c < s * 2
        SortAtScale(m, l, r, c)

        c = c * 2

```

3.2 Програмна реалізація алгоритму

3.2.1 Вихідний код

3.1.1.1 Звичайна реалізація алгоритму

```

import math
import os

def IntToRaw(value, intSize):
    overInt = 2 ** (8 * intSize)

    if not (-overInt <= value < overInt):
        raise ValueError('IntToRaw: too big number or too small number')

    if value < 0:
        value = overInt + value

    res = [0] * intSize

    for i in range(intSize):
        if value == 0:
            break

        res[i] = value & 0xff
        value >>= 8

    return res

def RawToInt(raw):
    overInt = 2 ** (8 * len(raw))
    res = 0

    for i, v in enumerate(raw):
        res += v * 2 ** (8 * i)

    if not (raw[-1] < 0x7f):
        res = res - overInt

    return res

def GetFileSize(fileName):
    return os.path.getsize(fileName)

```

```

def CreateIntArrayFile(fileName, length, intSize):
    rawZeroBytes = bytes(IntToRaw(0, intSize))

    with open(fileName, 'wb') as file:
        for i in range(length):
            file.write(rawZeroBytes)

class RWIntArrayFile:
    def __init__(self, fileName, length, intSize):
        self.file = open(fileName, 'r+b')
        self.length = length
        self.intSize = intSize

    def GetInt(self, index):
        file = self.file
        length = self.length

        if not (0 <= index < length):
            raise IndexError('GetInt: invalid index')

        file.seek(index * self.intSize)

        rawInt = list(file.read(self.intSize))

        return RawToInt(rawInt)

    def SetInt(self, index, value):
        file = self.file
        length = self.length
        intSize = self.intSize

        if not (0 <= index < length):
            raise IndexError('SetInt: invalid index')

        file.seek(index * intSize)

        try:
            rawIntBytes = bytes(IntToRaw(value, intSize))
        except:
            raise ValueError('SetInt: value of input integer is not in
bounds')

        file.write(rawIntBytes)

    def Length(self):
        return self.length

    def IntSize(self):
        return self.intSize

    def __del__(self):
        self.file.close()

def MergeAt(m, l, r, chk, m_idx, l_beg, l_sz, r_beg, r_sz):
    l_idx = l_beg
    r_idx = r_beg

    while (l_idx < l_sz and l_idx - l_beg < chk) and (r_idx < r_sz and
r_idx - r_beg < chk):

```



```

        l_val = l.GetInt(l_idx)
        r_val = r.GetInt(r_idx)

        if l_val <= r_val:
            m.SetInt(m_idx, l_val)
            l_idx += 1
        else:
            m.SetInt(m_idx, r_val)
            r_idx += 1

        m_idx += 1

    while l_idx < l_sz and l_idx - l_beg < chk:
        m.SetInt(m_idx, l.GetInt(l_idx))
        l_idx += 1
        m_idx += 1

    while r_idx < r_sz and r_idx - r_beg < chk:
        m.SetInt(m_idx, r.GetInt(r_idx))
        r_idx += 1
        m_idx += 1

def SortAtScale(m, l, r, c):
    s = m.Length()

    ls = 0
    rs = 0

    for i in range(s):
        lrChoice = (i // c) & 1

        blockOffset = i // (2 * c) * c
        index = i % c

        [l, r][lrChoice].SetInt(
            blockOffset + index
            , m.GetInt(i)
        )

        if lrChoice == 0:
            ls += 1
        else:
            rs += 1

    m_idx = 0
    lr_idx = 0

    while m_idx < s:
        MergeAt(
            m, l, r,
            c,
            m_idx,
            lr_idx, ls,
            lr_idx, rs
        )

        m_idx += 2 * c
        lr_idx += c

def DirectMergeSort(m, l, r):
    s = m.Length()

```

```

c = 1
while c < s * 2:
    SortAtScale(m, l, r, c)

    c *= 2

def main():
    BlockSize = 2 ** 20

    IntSize = 8
    Length = GetFileSize('A.qwa') // IntSize

    CreateIntArrayFile('B.qwa', Length, IntSize)
    CreateIntArrayFile('C.qwa', Length, IntSize)

    mainFile = RWIntArrayFile('A.qwa', Length, IntSize, blockSize =
BlockSize)
    leftFile = RWIntArrayFile('B.qwa', Length, IntSize, blockSize =
BlockSize)
    rightFile = RWIntArrayFile('C.qwa', Length, IntSize, blockSize =
BlockSize)

    DirectMergeSort(mainFile, leftFile, rightFile)

    mainFile.FlushCache()
    leftFile.FlushCache()
    rightFile.FlushCache()

if __name__ == '__main__':
    main()

```

3.2.1.2 Модифікована реалізація алгоритму на мові Python 3

```

import os

def IntToRaw(value, intSize):
    return value.to_bytes(intSize, byteorder='little', signed=True)

def RawToInt(raw):
    return int.from_bytes(raw, byteorder='little', signed=True)

def GetFileSize(fileName):
    return os.path.getsize(fileName)

def CreateIntArrayFile(fileName, length, intSize):
    with open(fileName, 'wb') as file:
        for i in range(length):
            file.write(IntToRaw(0, intSize))

class RWIntArrayFile:
    def __init__(self, fileName, length, intSize, *, blockSize=4096):
        if not (0 <= blockSize and (blockSize & (blockSize - 1) == 0)):
            raise ValueError('a block size has to be a power of 2')

        self.fileName = fileName
        self.length = length
        self.intSize = intSize
        self.blockSize = blockSize
        self.blockSizeMask = blockSize - 1
        self.blockSizeBitShift = blockSize.bit_length() - 1

```

```

        self.blockSizeMulIntSize = self.intSize << self.blockSizeBitShift
        self.cache = bytearray(blockSize * intSize)
        self.cache_start_index = -1
        self.cache_size = 0
        self.file = None
        self._open_file()

    def _open_file(self):
        try:
            self.file = open(self.fileName, 'r+b')
        except IOError as e:
            print(f"Error opening file: {e}")
            raise

    def _load_block(self, block_index):
        try:
            self.file.seek(block_index * self.blockSizeMulIntSize)
            read_size = self.blockSizeMulIntSize
            bytes_read = self.file.read(read_size)
            self.cache_size = len(bytes_read)
            self.cache[:self.cache_size] = bytes_read
            self.cache_start_index = block_index
        except IOError as e:
            print(f"Error loading block: {e}")
            raise

    def _flush_cache(self):
        if self.cache_start_index == -1:
            return

        try:
            self.file.seek(self.cache_start_index *
self.blockSizeMulIntSize)
            self.file.write(self.cache[:self.cache_size])
            self.file.flush()
            self.cache_start_index = -1
            self.cache_size = 0
        except IOError as e:
            print(f"Error flushing cache: {e}")
            raise

    def _get_cache_offset(self, index):
        return (index & self.blockSizeMask) * self.intSize

    def GetInt(self, index):
        block_index = index >> self.blockSizeBitShift
        offset = self._get_cache_offset(index)

        if self.cache_start_index != block_index:
            self._flush_cache()
            self._load_block(block_index)

        rawInt = self.cache[offset:offset + self.intSize]
        return RawToInt(rawInt)

    def SetInt(self, index, value):
        block_index = index >> self.blockSizeBitShift
        offset = self._get_cache_offset(index)

        if self.cache_start_index != block_index:
            self._flush_cache()

```

```

        self._load_block(block_index)

        rawIntBytes = bytes(IntToRaw(value, self.intSize))

        self.cache[offset:offset + self.intSize] = rawIntBytes

    def Length(self):
        return self.length

    def IntSize(self):
        return self.intSize

    def FlushCache(self):
        self._flush_cache()

    def __enter__(self):
        self._open_file()
        return self

    def __exit__(self, exc_type, exc_val, exc_tb):
        self._flush_cache()
        self.file.close()

    def __del__(self):
        if self.file:
            self._flush_cache()
            self.file.close()

def MergeAt(m, l, r, chk, m_idx, l_beg, l_sz, r_beg, r_sz):
    l_idx = l_beg
    r_idx = r_beg

    while (l_idx < l_sz and l_idx - l_beg < chk) and (r_idx < r_sz and
r_idx - r_beg < chk):
        l_val = l.GetInt(l_idx)
        r_val = r.GetInt(r_idx)

        if l_val <= r_val:
            m.SetInt(m_idx, l_val)
            l_idx += 1
        else:
            m.SetInt(m_idx, r_val)
            r_idx += 1

        m_idx += 1

    while l_idx < l_sz and l_idx - l_beg < chk:
        m.SetInt(m_idx, l.GetInt(l_idx))
        l_idx += 1
        m_idx += 1

    while r_idx < r_sz and r_idx - r_beg < chk:
        m.SetInt(m_idx, r.GetInt(r_idx))
        r_idx += 1
        m_idx += 1

def SortAtScale(m, l, r, c):
    s = m.Length()

```

```

ls = 0
rs = 0

for i in range(s):
    lrChoice = (i // c) & 1

    blockOffset = i // (2 * c) * c
    index = i % c

    [l, r][lrChoice].SetInt(
        blockOffset + index
        , m.GetInt(i)
    )

    if lrChoice == 0:
        ls += 1
    else:
        rs += 1

m_idx = 0
lr_idx = 0

while m_idx < s:
    MergeAt(
        m, l, r,
        c,
        m_idx,
        lr_idx, ls,
        lr_idx, rs
    )

    m_idx += 2 * c
    lr_idx += c

def DirectMergeSort(m, l, r):
    s = m.Length()

    c = 1
    while c < s:
        SortAtScale(m, l, r, c)

        c *= 2

def main():
    BlockSize = 1024 * 2 ** 10

    IntSize = 8
    Length = GetFileSize('A.qwa') // IntSize

    CreateIntArrayFile('B.qwa', Length, IntSize)
    CreateIntArrayFile('C.qwa', Length, IntSize)

    mainFile = RWIntArrayFile('A.qwa', Length, IntSize, blockSize =
BlockSize)
    leftFile = RWIntArrayFile('B.qwa', Length, IntSize, blockSize =
BlockSize)
    rightFile = RWIntArrayFile('C.qwa', Length, IntSize, blockSize =
BlockSize)

    DirectMergeSort(mainFile, leftFile, rightFile)

```

```

        mainFile.FlushCache()
        leftFile.FlushCache()
        rightFile.FlushCache()

    if __name__ == '__main__':
        main()

```

3.2.1.3 Модифікована реалізація алгоритму на мові C++

```

#include <iostream>
#include <fstream>
#include <vector>
#include <cstring>
#include <stdexcept>
#include <cstdint>
#include <filesystem>
#include <cmath>

std::vector<char> IntToRaw(std::int64_t value, std::size_t intSize)
{
    std::vector<char> raw(intSize);

    for (std::size_t i = 0; i < intSize; ++i)
    {
        raw[i] = (value >> (i * 8)) & 0xFF;
    }
    return raw;
}

std::int64_t RawToInt(const std::vector<char>& raw)
{
    std::int64_t value = 0;

    for (std::size_t i = 0; i < raw.size(); ++i)
    {
        value |= (static_cast<int64_t>(static_cast<unsigned char>(raw[i]))) << (i
* 8));
    }
    return value;
}

std::size_t GetFileSize(const std::string& fileName)
{
    return std::filesystem::file_size(fileName);
}

```

```

}

void CreateIntArrayFile(const std::string& fileName, std::size_t length,
std::size_t intSize)
{
    std::ofstream file(fileName, std::ios::binary);
    std::vector<char> zeroBytes(intSize, 0);

    for (std::size_t i = 0; i < length; ++i)
    {
        file.write(zeroBytes.data(), intSize);
    }
}

class RWIntArrayFile
{
private:
    std::string fileName;
    std::size_t length;
    std::size_t intSize;
    std::size_t blockSize;

    std::size_t blockSizeMask;
    std::size_t blockSizeBitShift;
    std::size_t blockSizeMulIntSize;

    std::vector<char> cache;
    int64_t cache_start_index;
    std::size_t cache_size;

    std::ifstream readFile;
    std::ofstream writeFile;

    void CloseReadFile()
    {
        if (readFile.is_open())
        {
            readFile.close();
        }
    }

    void CloseWriteFile()
    {

```

```

        if (writeFile.is_open())
        {
            writeFile.close();
        }
    }

void OpenReadFile() {
    if (!readFile.is_open())
    {
        CloseWriteFile();

        readFile.open(fileName, std::ios::in | std::ios::binary);
        if (!readFile.is_open())
        {
            throw std::runtime_error("Failed to open file for reading");
        }
    }
}

void OpenWriteFile() {
    if (!writeFile.is_open())
    {
        CloseReadFile();

        writeFile.open(fileName, std::ios::in | std::ios::out |
std::ios::binary);
        if (!writeFile.is_open())
        {
            throw std::runtime_error("Failed to open file for writing");
        }
    }
}

public:
    RWIntArrayFile(
        const std::string& fileName
        , std::size_t length
        , std::size_t intSize
        , std::size_t blockSize = 4096
    )
    :
        fileName(fileName)
        , length(length)

```



```

        , intSize(intSize)
        , blockSize(blockSize)
        , cache(blockSize * intSize)
        , cache_start_index(-1)
        , cache_size(0)
    {
        if (!(blockSize > 0 && (blockSize & (blockSize - 1)) == 0))
        {
            throw std::invalid_argument("Block size must be a power of 2");
        }

        if (! (blockSize / intSize * intSize == blockSize))
        {
            throw std::invalid_argument("Block size has to be divided by the
size of integers of an array in a file");
        }

        blockSizeMask = blockSize - 1;
        blockSizeBitShift = static_cast<std::size_t>(std::log2(blockSize));
        blockSizeMulIntSize = intSize << blockSizeBitShift;

        OpenReadFile();
    }

~RWIntArrayFile()
{
    FlushCache();
    CloseReadFile();
    CloseWriteFile();
}

void FlushCache()
{
    if (cache_start_index == -1) return;

    OpenWriteFile();

    writeFile.seekp(cache_start_index * blockSizeMulIntSize, std::ios::beg);
    writeFile.write(cache.data(), cache_size);
    writeFile.flush();

    cache_start_index = -1;
    cache_size = 0;
}

```

```

        CloseWriteFile();
    }

void LoadBlock(std::size_t block_index)
{
    OpenReadFile();

    readFile.seekg(block_index * blockSizeMulIntSize, std::ios::beg);
    readFile.read(cache.data(), blockSizeMulIntSize);

    cache_size = readFile.gcount();
    cache_start_index = block_index;

    CloseReadFile();
}

std::size_t GetCacheOffset(std::size_t index)
{
    return (index & blockSizeMask) * intSize;
}

std::int64_t GetInt(std::size_t index)
{
    std::size_t block_index = index >> blockSizeBitShift;
    std::size_t offset = GetCacheOffset(index);

    if (cache_start_index != static_cast<int64_t>(block_index))
    {
        FlushCache();
        LoadBlock(block_index);
    }

    std::vector<char> rawInt(cache.begin() + offset, cache.begin() + offset
+ intSize);
    return RawToInt(rawInt);
}

void SetInt(std::size_t index, int64_t value)
{
    std::size_t block_index = index >> blockSizeBitShift;
    std::size_t offset = GetCacheOffset(index);

```

```

        if (cache_start_index != static_cast<int64_t>(block_index))
        {
            FlushCache();
            LoadBlock(block_index);
        }

        auto rawIntBytes = IntToRaw(value, intSize);
        std::copy(rawIntBytes.begin(), rawIntBytes.end(), cache.begin() +
offset);

        cache_start_index = block_index;
    }

    std::size_t Length() const
    {
        return length;
    }

    std::size_t IntSize() const
    {
        return intSize;
    }
};

void MergeAt(RWIntArrayFile& m, RWIntArrayFile& l, RWIntArrayFile& r,
std::size_t chk, std::size_t m_idx, std::size_t l_beg, std::size_t l_sz,
std::size_t r_beg, std::size_t r_sz)
{
    std::size_t l_idx = l_beg;
    std::size_t r_idx = r_beg;

    while ((l_idx < l_sz && l_idx - l_beg < chk) && (r_idx < r_sz && r_idx -
r_beg < chk))
    {
        int64_t l_val = l.GetInt(l_idx);
        int64_t r_val = r.GetInt(r_idx);

        if (l_val <= r_val)
        {
            m.SetInt(m_idx++, l_val);
            l_idx++;
        }
        else

```

```

        {
            m.SetInt(m_idx++, r_val);
            r_idx++;
        }
    }

    while (l_idx < l_sz && l_idx - l_beg < chk)
    {
        m.SetInt(m_idx++, l.GetInt(l_idx++));
    }

    while (r_idx < r_sz && r_idx - r_beg < chk)
    {
        m.SetInt(m_idx++, r.GetInt(r_idx++));
    }
}

void SortAtScale(RWIntArrayFile& m, RWIntArrayFile& l, RWIntArrayFile& r,
std::size_t c)
{
    std::size_t s = m.Length();

    std::size_t ls = 0;
    std::size_t rs = 0;

    for (std::size_t i = 0; i < s; ++i)
    {
        std::size_t lrChoice = (i / c) & 1;

        std::size_t blockOffset = i / (2 * c) * c;
        std::size_t index = i % c;

        (lrChoice == 0 ? l : r).SetInt(blockOffset + index, m.GetInt(i));

        if (lrChoice == 0)
        {
            ls++;
        }
        else
        {
            rs++;
        }
    }
}

```

```

std::size_t m_idx = 0;
std::size_t lr_idx = 0;

while (m_idx < s)
{
    MergeAt(m, l, r, c, m_idx, lr_idx, ls, lr_idx, rs);
    m_idx += 2 * c;
    lr_idx += c;
}
}

void DirectMergeSort(RWIntArrayFile& m, RWIntArrayFile& l, RWIntArrayFile& r)
{
    std::size_t s = m.Length();
    std::size_t c = 1;
    while (c < s)
    {
        SortAtScale(m, l, r, c);
        c *= 2;
    }
}

int main()
{
    constexpr std::size_t BlockSize = 4096 * (1 << 10);
    constexpr std::size_t IntSize = 8;

    std::size_t Length = GetFileSize("A.qwa") / IntSize;

    CreateIntArrayFile("B.qwa", Length, IntSize);
    CreateIntArrayFile("C.qwa", Length, IntSize);

    RWIntArrayFile mainFile("A.qwa", Length, IntSize, BlockSize);
    RWIntArrayFile leftFile("B.qwa", Length, IntSize, BlockSize);
    RWIntArrayFile rightFile("C.qwa", Length, IntSize, BlockSize);

    DirectMergeSort(mainFile, leftFile, rightFile);

    mainFile.FlushCache();
    leftFile.FlushCache();
    rightFile.FlushCache();
}

```

```
    return 0;  
}
```

Програмна реалізація на мові «Python 3» та C++ є коректними [1] та швидкими після проведення пробних запусків завчасно. Для виконання програмного забезпечення було використано JIT компілятор PyPy3 з метою пришвидшення виконання програмного забезпечення. Шел та середовище виконання програмного забезпечення:

1. OS: «Linux sudo-su-sie 6.9.9-zen1-1-zen #1 ZEN SMP PREEMPT_DYNAMIC Fri, 12 Jul 2024 00:06:19 +0000 x86_64 GNU/Linux»;
2. Python: «Python 3.12.4»;
3. PyPy3: «Python 3.10.14 (39dc8d3c85a7, Aug 30 2024, 08:27:45) [PyPy 7.3.17 with GCC 14.2.1 20240805]»;
4. ROM: SSD.
5. RAM: 16 Gb.
6. CPU: 1.6 GHz, 8 ccores.
7. G++: «g++ (GCC) 14.1.1 20240522»
8. C++: «g++ -O3 main.cpp -o main.exe»

Під час проведення внутрішнього профайлінгу програмного забезпечення було виявлено кілька вузьких місць в програмі як операції зчитування та запису до файлів, які додавали значну кількість часу практичного виконання програмної реалізації.

Під час модифікації алгоритму було прийнято рішення використовувати агресивне кешування файлів, чий буфер займає достатньо багато місця (десь 1Мб на файл) для нівелювання затрат на велику кількість системних викликів операційної системи, також щоб пришвидшення таких основних операцій алгоритму, як запис до файлів на жорсткому диску. Під час вимірювання практичного часу виконання програми було встановлено, що використання кешування збільшило швидкодію програмного забезпечення на вхідних даних малого розміру (з 56Кб).

Також при профайлінгу було помічено, що абстраговані операції зчитування та запису до файлу через клас-обертку є досить неоптимізованими з точки зору арифметичних та математичних дій, тому було замінено всі операції ділення на модуль на побітове «і» використовуючи маски. Повторюючі операції, які включали подалі незмінювані зміни, були заздалегіть обрахованими під час створення класу-обертку. Єдиним недоліком є те, що розмір кеш-блоку має бути ступінню 2.

Нижче (таблиця 3.3.1) наведено приклад виконання програмного забезпечення без та з «PyPy3» замість «CPython» та з та без використання кешування файлів.

Таблиця 3.3.1 — Практичний час виконання програмного забезпечення при вхідних умовах різного типу

Номер тесту	З PyPy3?	З кешування файлів (десь 1Мб на файл)?	Розмір вхідних даних (Кб)	Практичний час виконання (с.)
1	—	—	56	1.721
2	+	—	56	1.678
3	—	+	56	0.341
4	+	+	56	0.163
5	+	+	200	0.293
6	+	+	640	0.791
7	+	+	2364	2.658
8	+	+	7088	8.603

Так як теоретична часова складність алгоритму [1] є $O(n \log n)$, то пратична часова складність програмної реалізації при найкращих умовах (таблиця 3.3) та середовиз після підрахунків методом виведення константи швидкодії, тому приблизним результатом буде: $t(x:\text{байти})=0.000000077 \times \ln x[\text{сек.}]$, час при вхідних даних розміром в мегабайти: $t(x:\text{Мб})=0.077 \times \ln x[\text{сек.}]$. Нижче (таблиця 3.3.2)

наведено час виконання програмної реалізації використовуючи апроксимовані формули практичного часу виконання при найкращих умовах та модифікацій.

Таблиця 3.3.2 — Практичний час виконання використовуючи теоретичні методи та апроксимації

Номер практичного тесту	Розмір файлу (Мб)	Практичний час виконання за теоретично-практичними формулами
1	100	2.3 хв.
2	300	7.5 хв.
3	1 000	26 хв.
4	3 000	84 хв.
5	10 000	4.9 г.
6	30 000	15.5 г.
7	100 000	2.5 д.
8	300 000	7 д.

Швидкість виконання програмної реалізації на мові Python є незадовільними та відстають по ліміту практичного часу виконання в 4.33 разів. Так як мова Python є динамічно типізованою, то можливостей для оптимізації PyPy3 не так і багато. Єдиним можливим кроком є перехід на мову зі статичною типізацією як C++.

Практичний час виконання на мові C++ (таблиця 3.3.3) використовуючи усі практики оптимізації та пришвидшення коду наведено нижче.

Таблиця 3.3.3 — практичний час виконання на мові C++ на даних різного розміру

Номер практичного тесту	Розмір файлу (Мб)	Практичний час виконання (с.)
-------------------------	-------------------	-------------------------------

1	1	0.366
2	3	1.146
3	10	4.029
4	30	13.104
5	100	48.389

Як і минулого разу, практичний час виконання програмної реалізації на мові C++ вже буде становити: $f(x: \text{кіль-ть. байтів}): \text{сек.} = 0.000000024987 \times \log(x) [1]$.

Таблиця практично-теоретичного часу виконання програмної реалізації на мові C++ наведено в таблиці 3.3.4 по виведеній формулі часу виконання за практичними .

Таблиця 3.3.4 — практично-теоретичний час виконання програмної реалізації на мові C++ по формулі вище

Номер теоретичного тесту	Розмір файлу (Мб)	Практичний час виконання
1	100	48.389 с.
2	300	2.563 хв.
3	1000	9.070 хв.
4	3000	28.650 хв.
5	10000	1.679 г.
6	16384	2.810 г.
7	32768	5.785 г.
8	65536	11.902 г.
9	131072	24.465 г.
10		

ВИСНОВОК

Під час перевірки коректності виконання алгоритму було виявлено, що результат сортування в масиві чисел в файлі є коректним. Псевдокод алгоритму зовнішнього сортування є достатньо компактним, тому виникнення помилок є більш малоймовірним. Програмна реалізація була створена мовами Python 3 та C++.

При виконанні даної лабораторної роботи не вийшло реалізувати достатньо швидкодіяну програмну реалізацію на мові «Python 3» при використанні найкращих модифікацій та програмного забезпечення. Але на C++ результат є практично задовільним.

Було виявлено, що такі операції з файлами, як зчитування та запис є дуже повільними, мається на увазі, що операції значно знижують швидкодію програмного забезпечення. Також створено та впроваджено кешування файлів для збільшення швидкодії програмного забезпечення. За результатами цієї впровадженої модифікації швидкодія була значно збільшена. Використання JIT компілятора «PyPy3» дало значне покращення швидкодії. Також було створено нову програмну реалізацію на мові C++ для покращення швидкодії.

Окремо кажучи, багаточисленні та часті операції над змінними були оптимізовані на більш швидкі та більш оптимізовані альтернативи. На жаль розмір кеш-блоку має бути ступінню 2.

Час виконання алгоритму є практично задовільним та відстає від попередньо встановленого часу лаборантом в 300 секунд (6 хвилин) в 1.814 разів при використанні програмної реалізації на мові C++.

Результатом виконання цієї лабораторної роботи є практично задовільно. Відставання від встановленого ліміту часу лаборантом цієї практичної роботи є достатньо незначним.

ПОСИЛАННЯ НА ДЖЕРЕЛА

- [1] Головченко Максим Миколайович (2023). Проектування алгоритмів. Факультет інформатики та обчислювальної техніки, Кафедра інформатики та програмної інженерії.

КРИТЕРІЇ ОЦІНЮВАННЯ

Максимальний бал за виконання лабораторної роботи дорівнює – 5.

Критерії оцінювання у відсотках від максимального балу:

- псевдокод алгоритму – 15%;
- програмна реалізація алгоритму – 30%;
- програмна реалізація модифікацій – 40%;
- робота з git – 10%;
- висновок – 5%.